

MAPA CONCEPTUAL

PROBLEMA CENTRAL

La carencia de **metodologías** estandarizadas de evaluación cualitativa y la incapacidad de los algoritmos de clustering tradicionales para adaptarse de manera autónoma a flujos de datos dinámicos, de alta dimensionalidad y sensibles a la privacidad, lo que genera métricas de rendimiento engañosas y limita una validación tecnológica rigurosa en aplicaciones del mundo real.

Universidad Nacional de
Loja

Francis Valdiviezo
Metodología de la investigación

1. CONTEXTO

El problema se desarrolla dentro del área de Minería de Flujos de Datos (Data Stream Mining) y el aprendizaje automático no supervisado. Ocurre bajo diversas exigencias tecnológicas y sociales:

- **Entornos IoT:** Dispositivos que generan volúmenes infinitos y continuos de datos en tiempo real, requiriendo un procesamiento con baja capacidad computacional.
- **Redes de Aprendizaje Federado:** Entornos descentralizados con datos "No IID" (no independientes e idénticamente distribuidos), exigiendo una estricta protección de la privacidad.
- **Plataformas Educativas (MOOCs):** Datos de comportamiento altamente dispersos y dimensionales, necesitando análisis para personalizar la enseñanza.
- **Ingeniería de Materiales:** Transición desde la optimización de hardware guiada por la experiencia humana, hacia el análisis estadístico guiado por datos (ej. características de desgaseificación al vacío).

2. ACTORES INVOLUCRADOS

- **Investigadores y desarrolladores de algoritmos:** Carecen de un consenso, conjuntos de datos reales y catálogos estandarizados (benchmarks) para validar y comparar el agrupamiento de forma justa.
- **Dispositivos de Borde (Edge) y Sensores IoT:** Sistemas de hardware directamente afectados por el alto consumo de memoria y cuellos de botella al procesar modelos dinámicos.
- **Usuarios de redes federadas (Grupos mayoritarios y minoritarios):** Clientes o individuos cuyas bases de datos corren el riesgo de sufrir Ataques de Inferencia de Membresía (MIA) si los algoritmos segmentan demasiado la información.
- **Estudiantes en línea:** Sus perfiles de aprendizaje son analizados bajo modelos de clustering para recibir recomendaciones y adaptar metodologías.

3. VARIABLES O ELEMENTOS CENTRALES

- **Deriva de Concepto (Concept Drift):** Cambios evolutivos (súbitos, graduales o incrementales) en la distribución subyacente de un flujo de datos a lo largo del tiempo, lo cual invalida modelos estáticos.
- **Índices de Validación de Clústeres (CVIs e iCVIs):** Métricas matemáticas (como Pureza, Silhouette, Suma de Errores Cuadrados) que miden la calidad del clúster: su uso actual infla resultados al ignorar características cualitativas frente a la pura velocidad.
- **Riesgo de Inferencia de Membresía (MIA):** Vulnerabilidad a la privacidad donde un atacante puede deducir si el dato de un individuo fue usado para entrenar un modelo específico.
- **Modelos de Ventanas de Tiempo (Time Windows):** Técnicas (deslizantes, atenuadas, de hitos) utilizadas por los algoritmos para olvidar datos históricos y concentrarse en flujos recientes.
- **Dispersión y Dimensionalidad:** Dificultad para calcular métricas de distancia (como la Euclidiana) con alta fiabilidad cuando los conjuntos de datos son masivos y complejos.

4. RELACIÓN CAUSAL

El contexto impone exigencias de datos dinámicos, distribuidos y de alta complejidad.

Estas condiciones afectan a los actores involucrados.

Lo anterior se ve intensificado por variables críticas (deriva de concepto, alta dimensionalidad, métricas inadecuadas, riesgo MIA, etc.).

Como resultado, se genera el problema central: métricas engañosas y falta de validación tecnológica rigurosa en aplicaciones del mundo real.

5. POSIBLES OBJETIVOS

Objetivo General

Desarrollar y evaluar marcos de clustering dinámicos que se adapten autónomamente a flujos de datos complejos y derivas de concepto, mitigando riesgos de privacidad y validando sus resultados mediante metodologías e índices cualitativos estandarizados.

Objetivos Específicos

- **Adaptabilidad Estocástica:** Integrar técnicas probabilísticas (como el Proceso de Dirichlet) y modelos incrementales para clasificar flujos de datos IoT sin necesidad de predefinir el número de clústeres.
- **Protección de Privacidad:** Diseñar funciones de selección de clústeres en entornos federados que evalúen activamente el riesgo MIA, logrando un equilibrio de Pareto entre el rendimiento del modelo y la privacidad de los grupos minoritarios.
- **Optimización Computacional:** Implementar arquitecturas de reducción de características (como redes Autoencoder) y eliminación de datos mediante funciones kernel para operar eficientemente en dispositivos con memoria limitada.
- **Estandarización de Evaluaciones:** Incorporar la aplicación de índices incrementales (ICVIs) y métricas de calidad de clúster para auditar objetivamente las estructuras, evitando las puntuaciones engañosas provenientes del fraccionamiento excesivo.

REFERENCIAS

- [1] C. Nordahl, V. Boeva, H. Grah, and M. Persson-Netz, "On Evaluation of Data Stream Clustering Algorithms: A Survey," Aug. 03, 2025, IEEE Access, Karlskrona, Sweden. doi: 10.1109/ACCESS.2025.3596435.
- [2] A. Chowdhury, A. Pal, A. Raut, and M. Kumar, "KIHCDP: An Incremental Hierarchical Clustering Approach for IoT Data Using Dirichlet Process," IEEE Access, vol. 12, pp. 56019–56032, Apr. 2024, doi: 10.1109/ACCESS.2024.3385628.

- [3] X. Lian, J. Chen, and C. Duan, "Research on Data Analysis of Vacuum Outgassing Characteristics of Encapsulating Materials Based on Hybrid Clustering Algorithm," ACM, Nov. 2025, pp. 180–185. doi: 10.1145/3784013.3784041.
- [4] D. Fan, L. Fan, F. Zhao, H. Sun, and X. Min, "An Online Learner Clustering Algorithm Incorporating Autoencoder and Canopy-Kmeans," ICIEAI 2024, May 2025, pp. 627–633. doi: 10.1145/3724504.3724608.
- [5] K. Jung, S. Biswas, and C. Palamidessi, "Mitigating Membership Inference Vulnerability in Iterative Federated Clustering Algorithm," ARTMAN 2025, Nov. 2025, pp. 1–12. doi: 10.1145/3733821.3763022.