



Universidad
Nacional
de Loja

Universidad Nacional de Loja

Facultad de la Energía, las Industrias y los Recursos Naturales
No Renovables

Carrera de Computación

Ética y Responsabilidad en el Uso de la Inteligencia
Artificial Generativa

Ethics and Responsibility in the Use of Generative
Artificial Intelligence

Metodología de la Investigación en
Computación.

AUTOR:

Francis Josue Valdiviezo Jimenez

TUTOR:

Prof. Luis Chamba-Eras

Loja, Ecuador

2026

Declaración de uso de IA Generativa

Yo, **Francis Josue Valdiviezo Jimenez**, en calidad de autor, declaro de manera transparente y responsable el uso de herramientas de Inteligencia Artificial Generativa (IAG) durante el desarrollo del presente trabajo, en conformidad con los principios de integridad académica, ética investigativa y buenas prácticas en el uso de tecnologías emergentes.

1. Alcance del uso de IA generativa

El uso de herramientas de IAG se ha limitado a funciones de apoyo, sin sustituir el juicio crítico ni la autoría intelectual del autor. En particular, se han utilizado para:

- Mejora de redacción y estilo académico.
- Generación de ideas preliminares.
- Apoyo en la estructuración del documento.
- Asistencia en traducción técnica.

2. Clasificación del uso según GAIDeT

De acuerdo con la taxonomía GAIDeT, el uso de IA generativa en este trabajo se clasifica en:

- **Nivel 1 – Asistencia Lingüística:** Corrección gramatical y mejora de claridad.
- **Nivel 2 – Apoyo en Ideación:** Generación de ideas y esquemas conceptuales.
- **Nivel 3 – Asistencia Técnica:** Apoyo en generación de código y explicaciones técnicas.

No se ha utilizado IA generativa para la generación autónoma de resultados ni para sustituir el análisis crítico del autor.

3. Validación y responsabilidad

Todo contenido asistido por IA ha sido revisado, validado y adaptado por el autor, quien asume la responsabilidad total sobre la calidad, veracidad y originalidad del trabajo.

4. Herramientas utilizadas

Se emplearon modelos de lenguaje (LLMs) de google NotebookLM, Gemini 3.1 pro, ChatGPT 5.2 y herramientas de asistencia técnica para redacción, estructuración y apoyo conceptual.

5. Consideraciones éticas

El uso de IA se realizó respetando principios de honestidad académica, normativas institucionales de la Universidad Nacional de Loja y buenas prácticas internacionales.

6. Declaración final

Declaro que el uso de IA generativa ha sido ético, transparente y complementario, sin comprometer la autoría ni la integridad académica del presente trabajo.

Loja, Ecuador, 19 de Mayo de 2026

Francis Josue Valdiviezo Jimenez

Autor

Índice General

Declaración de uso de IA Generativa	1
1 Introducción	4
1.1 Antecedentes	4
Referencias bibliográficas	7

1. Introducción

1.1. Antecedentes

El clustering jerárquico constituye una técnica importante dentro del aprendizaje no supervisado, debido a que permite organizar los datos en estructuras de varios niveles, generalmente representadas mediante dendrogramas o árboles. A diferencia de los métodos planos, como K-Means, los enfoques jerárquicos no solo asignan elementos a grupos, sino que también permiten observar relaciones de pertenencia, cercanía y subordinación entre los datos. Esta característica resulta útil en problemas donde se requiere comprender la estructura interna de la información y no únicamente obtener una partición final. En los últimos años, la investigación sobre clustering jerárquico se ha extendido hacia escenarios de mayor complejidad, como datos masivos, flujos continuos, información biomédica, imágenes, redes de sensores e Internet de las Cosas (IoT).

Uno de los antecedentes centrales para el análisis de flujos de datos es la evolución de los algoritmos de *data stream clustering*. Nordahl *et al.* realizaron una revisión sobre la evaluación de algoritmos de clustering en flujos de datos y señalan que, desde la aparición de BIRCH, el área ha priorizado métricas de rendimiento, velocidad y precisión, pero todavía presenta debilidades en la evaluación de la calidad real de los clústeres [1]. Este hallazgo es relevante porque evidencia que, aunque existen algoritmos capaces de procesar datos dinámicos, no siempre se cuenta con metodologías estandarizadas para comprobar si los grupos generados representan de manera adecuada la estructura de los datos. Además, los autores destacan la necesidad de usar índices de validación incrementales y bancos de prueba más sistemáticos para comparar algoritmos orientados al procesamiento continuo [1].

En relación con la escalabilidad, Monath *et al.* propusieron enfoques de clustering jerárquico capaces de trabajar con grandes volúmenes de información. En 2019, presentaron un método basado en gradientes que representa árboles jerárquicos en espacios hiperbólicos, permitiendo optimización continua y aprendizaje de extremo a extremo [2]. Posteriormente, desarrollaron un enfoque de clustering aglomerativo jerárquico escalable, aplicado incluso a miles de millones de consultas web, con resultados superiores frente a métodos tradicionales en coherencia de agrupamiento [3]. Estos trabajos

muestran que el clustering jerárquico ha dejado de ser una técnica limitada a conjuntos de datos pequeños y se ha convertido en una alternativa viable para escenarios de gran escala.

Otro avance relevante se relaciona con la robustez frente al ruido y con la actualización incremental de estructuras jerárquicas. Chien *et al.* propusieron HyperAid, un enfoque de reducción de ruido en espacios hiperbólicos antes del ajuste de árboles y del clustering jerárquico, logrando mejoras en la calidad de los árboles obtenidos [4]. Por su parte, Monath *et al.* desarrollaron algoritmos online de clustering jerárquico por niveles, los cuales actualizan las relaciones padre-hijo cuando ingresan nuevos datos y evitan reconstruir toda la jerarquía desde cero [5]. Estos aportes se relacionan directamente con los flujos de datos continuos, debido a que en estos entornos la información llega de forma constante, puede contener ruido y requiere mecanismos de adaptación sin reentrenamiento completo.

En aplicaciones recientes, el clustering jerárquico también se ha integrado con técnicas modernas de inteligencia artificial. Xie *et al.* utilizaron redes neuronales de grafos multidimensionales junto con clustering jerárquico de supernodos para selección de características en datos de microarrays de cáncer, abordando problemas de alta dimensionalidad y pocas muestras [6]. Pach *et al.* propusieron CoHiClust, un método de clustering jerárquico contrastivo auto-supervisado con visualización de nodos, orientado a obtener jerarquías más explicables en datos de imágenes [7]. Estos estudios demuestran que el clustering jerárquico no se limita a técnicas clásicas, sino que puede combinarse con aprendizaje profundo, grafos y modelos generativos para mejorar la representación, interpretación y utilidad práctica de los resultados.

Desde el punto de vista teórico, Bakkelund propuso una función objetivo para clustering jerárquico con preservación de orden, buscando equilibrar la similitud entre elementos y la conservación de relaciones estructurales en órdenes parciales o grafos dirigidos acíclicos [8]. Este antecedente aporta a la investigación porque muestra que aún existen desafíos formales para definir criterios de optimización adecuados en clustering jerárquico. De manera complementaria, Martín-Fernández *et al.* estudiaron el clustering jerárquico de variables en datos composicionales mediante transformaciones *log-ratio*, mostrando que la elección de la distancia y del método de enlace influye directamente en la validez de los resultados [9]. Esto refuerza la idea de que el rendimiento del clustering jerárquico depende tanto del algoritmo como de la representación matemática de los datos.

En contextos aplicados, el clustering jerárquico ha mostrado utilidad en control de calidad, agricultura inteligente e IoT. Qian *et al.* aplicaron dendrogramas, mapas de calor y análisis de componentes principales para controlar la calidad de electrodos de grafeno inducido por láser, logrando reducir la variación de las mediciones frente a la

selección manual [10]. Srinivasan *et al.* desarrollaron un algoritmo de fusión dinámica basado en clustering jerárquico para redes de sensores inalámbricos en agricultura inteligente, combinándolo con aprendizaje incremental para mejorar precisión y eficiencia energética [11]. Estos trabajos son importantes para el presente proyecto porque evidencian que los datos generados por sensores e infraestructuras distribuidas requieren modelos capaces de organizar información, reducir consumo de recursos y mantener desempeño en escenarios cambiantes.

De forma más específica para IoT y flujos dinámicos, Chowdhury *et al.* propusieron KIHCDP, un enfoque de clustering jerárquico incremental para datos IoT basado en procesos de Dirichlet [12]. Este trabajo aborda directamente la necesidad de adaptar el modelo a datos que llegan continuamente y que pueden presentar cambios en su distribución. La propuesta resulta especialmente cercana al objetivo del presente proyecto, ya que combina clustering jerárquico, procesamiento incremental y análisis de datos IoT, tres elementos centrales de la investigación planteada.

A partir de los antecedentes revisados, se observa que existe una base sólida sobre clustering jerárquico en grandes volúmenes de datos, espacios hiperbólicos, aprendizaje profundo, control de calidad, redes de sensores e IoT. Sin embargo, también se identifica una brecha: muchos estudios se enfocan en mejorar precisión o escalabilidad de manera aislada, mientras que otros se concentran en aplicaciones específicas sin comparar de forma integrada la estructura jerárquica, la adaptación incremental, el consumo de memoria y los tiempos de ejecución bajo flujos continuos con distribuciones dinámicas. Además, la literatura reciente señala que todavía falta estandarización en la evaluación de algoritmos de clustering para *streaming*, especialmente cuando se busca medir no solo velocidad, sino también calidad real de los clústeres [1]. Por ello, se justifica investigar el clustering jerárquico en flujos de datos continuos desde tres perspectivas complementarias: análisis estructural de mecanismos como BIRCH y modelos bayesianos, aplicación incremental en escenarios IoT y comparación experimental frente a algoritmos de partición tradicionales como K-Means.

Referencias bibliográficas

- [1] C. Nordahl, V. Boeva, H. Grahm, and M. Persson-Netz, “On evaluation of data stream clustering algorithms: A survey,” pp. 139 524–139 546, 8 2025. [Online]. Available: <https://doi.org/10.1109/ACCESS.2025.3596435>
- [2] N. Monath, M. Zaheer, D. Silva, A. McCallum, and A. Ahmed, “Gradient-based hierarchical clustering using continuous representations of trees in hyperbolic space,” in *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. Association for Computing Machinery, 7 2019, pp. 714–722.
- [3] N. Monath, K. A. Dubey, G. Guruganesh, M. Zaheer, A. Ahmed, A. McCallum, G. Mergen, M. Najork, M. Terzihan, B. Tjanaka, Y. Wang, and Y. Wu, “Scalable hierarchical agglomerative clustering,” in *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. Association for Computing Machinery, 8 2021, pp. 1245–1255. [Online]. Available: <https://doi.org/10.1145/3447548.3467404>
- [4] E. Chien, P. Tabaghi, and O. Milenkovic, “Hyperaid: Denoising in hyperbolic spaces for tree-fitting and hierarchical clustering,” in *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. Association for Computing Machinery, 8 2022, pp. 201–211.
- [5] N. Monath, M. Zaheer, and A. McCallum, “Online level-wise hierarchical clustering,” in *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. Association for Computing Machinery, 8 2023, pp. 1733–1745. [Online]. Available: <https://doi.org/10.1007/s10462-026-11490-0>
- [6] W. Xie, S. Zhang, L. Wang, K. Yu, and W. Li, “Feature selection of microarray data using multidimensional graph neural network and supernode hierarchical clustering,” *Artificial Intelligence Review*, vol. 57, pp. 1–29, 3 2024. [Online]. Available: <https://doi.org/10.1007/s10462-023-10700-3>

- [7] M. Pach, P. Rola, M. Znalezniak, P. Kaszuba, M. Przewiezlikowski, J. Tabor, and M. Śmieja, “Adaptive contrastive hierarchical clustering with nodes visualization,” *Artificial Intelligence Review*, vol. 59, pp. 1–27, 3 2026. [Online]. Available: <https://doi.org/10.1007/s10462-026-11490-0>
- [8] D. Bakkelund, “An objective function for order preserving hierarchical clustering,” *Machine Learning*, vol. 115, p. 107, 5 2026. [Online]. Available: <https://link.springer.com/10.1007/s10994-026-07046-6>
- [9] J. A. Martín-Fernández, V. D. Donato, V. Pawlowsky-Glahn, and J. J. Egozcue, “Insights in hierarchical clustering of variables for compositional data,” *Mathematical Geosciences*, vol. 56, pp. 415–435, 4 2024. [Online]. Available: <https://doi.org/10.1007/s11004-023-10115-4>
- [10] H. Qian, G. Moreira, D. Vanegas, Y. Tang, C. Pola, C. Gomes, E. McLamore, and N. Bliznyuk, “Improving high throughput manufacture of laser-inscribed graphene electrodes via hierarchical clustering,” *Scientific Reports*, vol. 14, pp. 1–11, 12 2024. [Online]. Available: <https://doi.org/10.1038/s41598-024-57932-z>
- [11] D. Srinivasan, A. Kiran, S. Parameswari, and J. Vellaichamy, “Energy efficient hierarchical clustering based dynamic data fusion algorithm for wireless sensor networks in smart agriculture,” *Scientific Reports*, vol. 15, pp. 1–24, 12 2025. [Online]. Available: <https://doi.org/10.1038/s41598-024-85076-7>
- [12] A. Chowdhury, A. Pal, A. Raut, and M. Kumar, “Kihcdp: An incremental hierarchical clustering approach for iot data using dirichlet process,” *IEEE Access*, vol. 12, pp. 56 019–56 032, 4 2024. [Online]. Available: <https://doi.org/10.1109/ACCESS.2024.3385628>