

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aplicación y Estructuración del Clustering Jerárquico en el Análisis Exploratorio de Datos	2
1.	Aplicación y Estructuración del Clustering Jerárquico en el Análisis Exploratorio de Datos	3
1.1.	Introducción	3
1.2.	Fundamentos Teóricos	4
1.2.1.	Concepto general	4
1.2.2.	Datos, distancias y enlace	4
1.2.3.	Validación e interpretación	5
1.3.	Metodología y Análisis de la Literatura	5
1.3.1.	Criterios de organización	5
1.3.2.	Flujo de aplicación	6
1.4.	Aplicaciones del Clustering Jerárquico	7
1.4.1.	Alimentos, consumidores y composición química	7
1.4.2.	Agua, ambiente y geociencias	7
1.4.3.	Salud, veterinaria y movimiento humano	7
1.4.4.	Sensores, IoT, educación y manufactura	8
1.4.5.	Desarrollos algorítmicos recientes	8
1.5.	Síntesis Comparativa	9
1.6.	Conclusiones	10

Parte I

Introducción y Fundamentos

Parte II

Aplicación y Estructuración del Clustering Jerárquico en el Análisis Exploratorio de Datos

Capítulo 1

Aplicación y Estructuración del Clustering Jerárquico en el Análisis Exploratorio de Datos

Autor: Francis Josue Valdiviezo Jimenez (francis.valdiviezo@unl.edu.ec)

Técnica asignada: Clustering Jerárquico

1.1. Introducción

El clustering jerárquico es una técnica de inteligencia artificial clásica orientada a descubrir estructuras de agrupamiento sin requerir etiquetas previas. Su valor principal en el análisis exploratorio de datos no consiste únicamente en separar observaciones, sino en representar relaciones de semejanza mediante una jerarquía. Esa jerarquía permite observar cómo se forman grupos pequeños, cómo se fusionan en grupos más amplios y en qué punto una partición resulta interpretable para el problema estudiado. En términos prácticos, el método ayuda a responder preguntas como: qué objetos son similares, qué variables explican esas similitudes, cuántos grupos pueden reconocerse y cómo se justifica esa agrupación frente al contexto de aplicación.

La literatura disponible muestra que el clustering jerárquico se ha utilizado en dominios muy distintos. En alimentos preparados, se aplicó para comparar composiciones nutricionales y apoyar la interpretación de diferencias entre preparaciones de restaurantes [1]. En proteómica, sirvió para explorar perfiles de expresión y evaluar la influencia de decisiones metodológicas como la transformación de datos, la medida de similitud y el método de agregación [2]. En desarrollo de productos alimentarios, se combinó con análisis de componentes principales para segmentar consumidores según patrones de agrado hacia jugos de naranja [3]. En química de alimentos, se utilizó junto con PCA para clasificar especias según actividad antioxidante y compuestos fenólicos [4]. Estos ejemplos permiten establecer una primera idea: el clustering jerárquico se aplica cuando el investigador necesita ordenar datos complejos en grupos interpretables y no conoce de antemano las clases correctas.

La amplitud de usos también aparece en estudios ambientales e hidrogeoquímicos. El método se ha empleado para evaluar calidad de aguas subterráneas mediante índices de contaminación y riesgo ecológico [5], para estudiar procesos hidrogeoquímicos asociados a contaminación espacial [6], para interpretar datos de Wadi El-Natrun en Egipto [7], y para organizar muestras de un acuífero volcánico del sur de Italia considerando la composición química de las aguas [8]. Además, en aguas embotelladas de Serbia se usó para clasificar marcas según cationes, aniones y sólidos disueltos totales [9]. En conjunto, estos estudios muestran que el clustering jerárquico es especialmente útil cuando los datos son multivariados, heterogéneos y requieren interpretación

contextual.

La pregunta de investigación de este capítulo es: *¿cómo se aplica el clustering jerárquico en análisis de datos?* Para responderla, el capítulo desarrolla tres niveles. Primero, se explican los fundamentos conceptuales del método: representación de datos, medidas de distancia, construcción de jerarquías y lectura del dendrograma. Segundo, se organiza un flujo metodológico basado en la literatura revisada. Tercero, se analizan aplicaciones concretas en alimentos, ambiente, salud, sensores, aprendizaje automático y sistemas distribuidos. Todas las afirmaciones se apoyan en las referencias del archivo bibliográfico disponible y, cuando se usan detalles de casos locales, estos proceden de los metadatos y textos de los artículos revisados.

1.2. Fundamentos Teóricos

1.2.1. Concepto general

El clustering jerárquico pertenece a los métodos de aprendizaje no supervisado. A diferencia de una clasificación supervisada, no parte de categorías conocidas; construye grupos a partir de semejanzas entre observaciones o variables. El resultado más característico es el dendrograma, una estructura en forma de árbol que muestra fusiones sucesivas entre elementos. En el enfoque aglomerativo, cada observación inicia como un grupo individual y el algoritmo fusiona los grupos más próximos hasta reunir todo el conjunto en un único árbol. En el enfoque divisivo ocurre lo contrario: se parte de un grupo global y se subdivide progresivamente.

La importancia del dendrograma está en que no entrega una sola respuesta cerrada. Permite observar varios niveles de agrupamiento. Si se corta el árbol cerca de la base se obtienen muchos grupos pequeños; si se corta más arriba, se obtienen pocos grupos grandes. Esta propiedad explica por qué el método es útil en exploración: el analista puede comparar particiones y relacionarlas con conocimiento del dominio. En proteómica, por ejemplo, Meunier et al. evaluaron cómo las decisiones de preprocesamiento, medición de similitud y agregación afectan la agrupación de perfiles de proteínas [2]. En estudios de alimentos y especias, la lectura de grupos ayudó a comparar preparaciones o muestras según atributos químicos y nutricionales [1, 4].

Desde la perspectiva de la inteligencia artificial clásica, el clustering jerárquico puede entenderse como una técnica de estructuración: transforma una matriz de datos en una representación relacional. Esa representación no sustituye el análisis estadístico, sino que lo complementa. En los estudios revisados, el método aparece con frecuencia junto a PCA, análisis de correspondencias múltiples, índices de contaminación, métodos de evaluación de calidad y modelos de aprendizaje automático [3, 10, 11]. Su uso más sólido surge cuando la jerarquía se interpreta junto con variables del problema y no como un resultado aislado.

1.2.2. Datos, distancias y enlace

La aplicación del clustering jerárquico comienza con una decisión central: cómo representar la semejanza entre objetos. En datos numéricos, se emplean distancias o medidas de similitud calculadas sobre variables estandarizadas o transformadas. En datos de composición química, por ejemplo, la escala de las variables puede cambiar por completo el resultado si no se normaliza. En el estudio de especias, Hossain et al. analizaron múltiples ensayos antioxidantes y compuestos fenólicos; el agrupamiento dependía de la combinación de esas variables [4]. En aguas embotelladas, Cvejanov y Skrbic organizaron marcas a partir de parámetros químicos como calcio, magnesio, sodio, potasio, cloruros, sulfatos, bicarbonatos y sólidos disueltos totales [9].

Una vez calculadas las distancias, el algoritmo necesita un criterio de enlace para decidir qué grupos se fusionan. Los enlaces pueden priorizar la distancia mínima entre miembros, la máxima, el promedio o criterios de varianza como Ward. La elección no es secundaria. Meunier et al. mostraron que la combinación de matriz transformada logarítmicamente, correlación de Pearson y método de Ward obtuvo buen desempeño en los datos proteómicos estudiados [2]. En

ortodoncia, Paddenberg-Schubert et al. emplearon distancias euclidianas y el método de Ward para estudiar diferencias entre grupos de pacientes esqueléticos de clase I y II, integrando después modelos de aprendizaje automático [11].

Cuando los datos tienen naturaleza especial, la distancia debe respetar esa estructura. En hidrogeoquímica, Ebrahimi et al. destacaron la relevancia de tratar datos composicionales para interpretar proporciones de bicarbonato, sulfato y cloruro en aguas subterráneas [8]. En datos composicionales más generales, Martín-Fernández et al. analizaron el clustering jerárquico de variables desde la geometría del simplex, lo que recuerda que no toda matriz multivariada puede tratarse como si sus variables fueran independientes y euclidianas [12]. Así, una aplicación rigurosa requiere que la distancia sea coherente con el tipo de dato.

1.2.3. Validación e interpretación

El clustering jerárquico produce una estructura, pero esa estructura debe validarse. La validación puede ser interna, cuando se evalúa la cohesión y separación de los grupos; externa, cuando se compara con etiquetas o conocimiento independiente; o contextual, cuando los grupos son interpretables para el problema. En proteómica se empleó la medida F para evaluar estrategias de agrupamiento [2]. En datos de precipitación, Tajbar et al. combinaron agrupamientos espaciales y temporales con variables geográficas y estadísticas, lo que permitió interpretar regiones homogéneas de precipitación en Khyber Pakhtunkhwa, Pakistán [13].

La validación también es importante en minería de datos continua. Nordahl et al. revisaron la evaluación de algoritmos de clustering en flujos de datos y observaron que muchas evaluaciones se concentran en rendimiento computacional y exactitud, mientras que la calidad de los grupos recibe menor atención [14]. Esto es relevante para clustering jerárquico porque la estructura puede verse convincente visualmente, pero no necesariamente ser estable o útil. En aplicaciones de sensores e Internet de las cosas, donde los datos llegan de manera continua, la evaluación debe considerar precisión, tiempo, estabilidad y costo computacional [15, 16].

Interpretar un dendrograma exige evitar dos errores frecuentes. El primero es asumir que el árbol revela clases naturales sin contrastarlas con el dominio. El segundo es decidir el número de grupos por conveniencia visual sin justificarlo. Los estudios revisados muestran mejores prácticas: relacionar los grupos con variables químicas en aguas [5, 6], con perfiles nutricionales en alimentos [1], con patrones de preferencia en consumidores [?], o con variables clínicas y cefalométricas en pacientes [11]. En todos los casos, el dendrograma funciona como una herramienta de análisis, no como una conclusión automática.

1.3. Metodología y Análisis de la Literatura

1.3.1. Criterios de organización

La metodología de este capítulo se basa en una revisión narrativa y técnica de las referencias disponibles en el archivo bibliográfico. Las fuentes fueron organizadas según el papel que cumplen en la pregunta de investigación: fundamentos algorítmicos, decisiones de aplicación, dominios empíricos, extensiones modernas y riesgos de evaluación. No se incorporan fuentes externas al conjunto bibliográfico. Cuando un artículo no desarrolla clustering jerárquico puro, se lo utiliza únicamente para el aspecto que sí está documentado: aprendizaje no supervisado, agrupamiento híbrido, evaluación, segmentación o integración con otros métodos.

La literatura puede agruparse en cinco familias. La primera incluye aplicaciones exploratorias clásicas en alimentos, consumidores, proteómica, aguas, ambiente y materiales [1–9, 13, 17, 18]. La segunda reúne usos en salud, veterinaria, biomecánica y odontología [10, 11, 19]. La tercera contiene aplicaciones en sensores, manufactura, educación, logística e IoT [15, 16, 20–23]. La cuarta incluye trabajos algorítmicos y teóricos sobre escalabilidad, métricas, optimización y aprendizaje profundo [24–30]. La quinta cubre evaluación, privacidad y consideraciones de

calidad [12, 14, 31–33]. Como referencia de contexto bibliográfico, el archivo incluye además las actas ISKE 2008, asociadas a sistemas inteligentes e ingeniería del conocimiento [34].

Esta organización permite responder cómo se aplica el método no solo desde la fórmula algorítmica, sino desde el ciclo completo de análisis. En los artículos empíricos, la aplicación suele iniciar con recolección y limpieza de datos; continúa con selección de variables, transformación, cálculo de distancias, construcción del dendrograma, selección de grupos y validación; finalmente, se interpreta cada grupo en función del contexto. En los artículos algorítmicos, la atención se desplaza hacia escalabilidad, representación continua de árboles, datos en línea, restricciones de orden y garantías aproximadas [24, 26–29].

1.3.2. Flujo de aplicación

Un flujo metodológico general para aplicar clustering jerárquico en análisis de datos puede organizarse en seis pasos. El primero es definir la unidad de análisis. En un estudio nutricional, la unidad puede ser una preparación alimentaria [1]; en hidrogeoquímica, una muestra de agua [8]; en precipitación, una celda de datos satelitales o un mes [13]; en ortodoncia, un paciente [11]. La claridad de la unidad evita mezclar interpretaciones incompatibles.

El segundo paso es seleccionar variables relevantes. Las variables deben representar el fenómeno y no solo estar disponibles. En alimentos, se usan componentes proximales, fibra, energía o compuestos antioxidantes [1, 4]. En aguas, se usan iones, metales, parámetros fisicoquímicos o índices de contaminación [5, 6, 9]. En sensores agrícolas, los datos de nodos de redes inalámbricas deben resumir condiciones ambientales y eventos relevantes [16]. En manufactura de electrodos de grafeno, Qian et al. usaron datos electroquímicos para control de calidad [20].

El tercer paso es preparar los datos. Esto incluye depuración, normalización, tratamiento de escalas y, si corresponde, transformación. En proteómica, la transformación logarítmica fue parte de las estrategias evaluadas [2]. En datos composicionales, la preparación debe respetar la naturaleza relativa de las variables [8, 12]. En IoT y logística, Wang y Hsu describen la necesidad de recolección, limpieza, deduplicación y estandarización de formatos antes de aplicar análisis de datos [21]. Sin este paso, el dendrograma puede reflejar artefactos de escala más que patrones reales.

El cuarto paso consiste en calcular distancias y elegir el método de enlace. La distancia debe corresponder al tipo de variable y al objetivo. Ward aparece en varios estudios como un criterio útil para formar grupos compactos [2, 11]. En cambio, cuando la tarea implica ajustar métricas de árbol o datos con geometría no euclidiana, se requieren enfoques más especializados. Chien et al. proponen HyperAid para denoising en espacios hiperbólicos y ajuste de árboles en datos ruidosos [25], mientras que Monath et al. exploran representaciones continuas de árboles en el espacio hiperbólico para optimización basada en gradiente [24].

El quinto paso es seleccionar el nivel de corte del dendrograma y describir los grupos. Esta decisión se justifica con métricas, estabilidad o interpretación. En aguas subterráneas, los grupos se relacionan con calidad apta o no apta, riesgo ecológico y procesos de contaminación [5, 6]. En precipitación, los grupos separan regiones o meses con diferentes comportamientos pluviométricos [13]. En consumidores, los grupos revelan segmentos con preferencias distintas [3]. En cada caso, el corte del dendrograma se vuelve útil cuando permite explicar diferencias sustantivas.

El sexto paso es validar y comunicar. La comunicación debe mostrar qué datos se agruparon, con qué variables, bajo qué distancia, qué grupos resultaron y qué significado tienen. Si el análisis se integra con modelos predictivos, se debe aclarar qué aporta el clustering frente al modelo. Paddenbergh-Schubert et al. combinaron clustering con modelos de machine learning para diagnóstico de clases esqueléticas [11]; Loughrey et al. propusieron detección de subgrupos dentro de grafos Mapper para medicina de precisión [32]; Xie et al. usaron una estructura de grafo y agrupamiento jerárquico para selección de características en microarreglos [33]. En estos trabajos, el clustering ayuda a estructurar el espacio de datos, mientras otros modelos realizan clasificación, selección o detección.

1.4. Aplicaciones del Clustering Jerárquico

1.4.1. Alimentos, consumidores y composición química

Los estudios de alimentos muestran una aplicación directa del clustering jerárquico como herramienta exploratoria. Da Silva Torres et al. analizaron alimentos preparados en restaurantes para comparar su composición nutricional. El agrupamiento permitió observar similitudes entre preparaciones y apoyar la educación del consumidor respecto a valores nutritivos [1]. En este caso, el método no busca predecir una clase futura, sino organizar información para facilitar decisiones y lectura comparativa.

Hossain et al. aplicaron PCA y HCA para clasificar especias según actividad antioxidante in vitro y compuestos polifenólicos. El clustering organizó las muestras con base en variables químicas, mientras PCA resumió la variabilidad principal [4]. La combinación ilustra una práctica recurrente: PCA ayuda a reducir y visualizar dimensiones, y HCA construye grupos interpretables. Varela, desde el desarrollo de productos, utilizó PCA y HCA para estudiar preferencias de consumidores hacia jugos de naranja, identificando segmentos de agrado durante el proceso de innovación alimentaria [3]. Así, el clustering jerárquico puede aplicarse tanto sobre propiedades objetivas de productos como sobre respuestas subjetivas de consumidores.

La enseñanza que dejan estos trabajos es metodológica. En datos alimentarios, las variables pueden mezclar composición, medidas sensoriales, respuesta hedónica y atributos funcionales. El clustering jerárquico permite comparar esos perfiles, pero su interpretación depende de elegir variables que tengan sentido para nutrición, calidad o desarrollo de producto. Por eso no basta con producir un dendrograma: se necesita explicar qué representa cada eje de variación y cómo los grupos informan una decisión.

1.4.2. Agua, ambiente y geociencias

El dominio ambiental es uno de los espacios donde el clustering jerárquico aparece con mayor claridad. En aguas embotelladas de Serbia, Cvejanov y Skrbic clasificaron marcas usando parámetros químicos principales y mostraron que PCA y HCA pueden apoyar una clasificación rápida de aguas según su composición [9]. En aguas subterráneas, Egbueri integró HCA con índices de contaminación y riesgo ecológico para distinguir muestras con diferentes niveles de aptitud para consumo [5]. Subba Rao y Chaudhary usaron HCA para relacionar variables químicas con procesos de salinidad, dureza y contaminación en un área sub-urbana de Visakhapatnam [6].

El-Dars y Sami aplicaron el método para interpretar datos hidrogeoquímicos de Wadi El-Natrun, considerando aguas superficiales y subterráneas [7]. Ebrahimi et al. lo usaron en un acuífero volcánico para agrupar muestras según especies aniónicas dominantes y discutir la evolución hidrogeoquímica del sistema [8]. En todos estos casos, el clustering jerárquico transforma tablas de mediciones químicas en grupos que pueden asociarse con procesos ambientales: mezcla de aguas, influencia geogénica, contaminación antrópica, calidad potable o condiciones hidrotermales.

También existen aplicaciones atmosféricas. Malley et al. aplicaron HCA y factorización no negativa de matrices para clasificar sitios europeos de monitoreo atmosférico según ozono, con el objetivo de evaluar representatividad de sitios de monitoreo [17]. Tajbar et al. estudiaron variabilidad temporal y espacial de precipitación mensual en Pakistán, agrupando datos de TRMM y relacionando los clusters con latitud, longitud, altitud y estadísticas de precipitación [13]. En geociencias, por tanto, el método ayuda a convertir variabilidad espacial y temporal en regiones, periodos o sitios con comportamiento homogéneo.

1.4.3. Salud, veterinaria y movimiento humano

En salud y ciencias biomédicas, el clustering jerárquico se utiliza para descubrir perfiles de pacientes, relaciones entre categorías o patrones de movimiento. El-Araby et al. combinaron aná-

lisis de correspondencias múltiples y HCA para perfilar relaciones entre predictores categóricos de riesgo en un caso de lengua azul; el análisis permitió identificar asociaciones entre categorías como resultados serológicos, edad y estación [10]. Este ejemplo es importante porque muestra que el clustering jerárquico no se limita a variables continuas: puede integrarse con técnicas que transforman categorías en espacios analizables.

Paddenberg-Schubert et al. analizaron pacientes ortodónticos alemanes para clasificar clases esqueléticas I y II, usando clustering jerárquico y varios modelos de aprendizaje automático. El clustering permitió examinar diferencias internas entre grupos, mientras los modelos supervisados evaluaron capacidad diagnóstica [11]. Djafari et al. estudiaron entrenamiento de step aeróbico en mujeres de mediana edad, usando análisis cinemático, costo de jerk y clustering jerárquico para identificar patrones de adaptación motora [19]. En estos contextos, el método ayuda a descubrir subgrupos que pueden tener significado clínico, biomecánico o preventivo.

La medicina de precisión también se beneficia de métodos de agrupamiento, aunque no siempre mediante HCA puro. Loughrey et al. propusieron detección de subgrupos en grafos Mapper para identificar comunidades homogéneas en datos de cáncer de mama [32]. Xie et al. abordaron selección de características en datos de microarreglos usando redes neuronales de grafos y descubrimiento de supernodos basado en clustering espectral e ideas jerárquicas [33]. Estos trabajos amplían la idea central: agrupar no es solo separar muestras, sino revelar estructura relevante para diagnóstico, estratificación y selección de variables.

1.4.4. Sensores, IoT, educación y manufactura

En sistemas de sensores, el clustering jerárquico ayuda a reducir redundancia, organizar nodos y mejorar el uso de recursos. Srinivasan et al. propusieron un algoritmo de fusión dinámica de datos basado en clustering jerárquico para redes inalámbricas de sensores en agricultura inteligente, orientado a eficiencia energética y detección de eventos [16]. Chowdhury et al. presentaron KIHCDP, un enfoque incremental para datos IoT con proceso de Dirichlet, dirigido a flujos de datos donde la distribución puede cambiar con el tiempo [15]. En ambos casos, el agrupamiento responde a una necesidad práctica: procesar datos abundantes, cambiantes y potencialmente redundantes.

En manufactura, materiales y control de calidad, Qian et al. aplicaron un flujo estadístico y una herramienta de clustering jerárquico para identificar electrodos de grafeno inscritos por láser con comportamiento similar, reduciendo variación en biosensores [20]. Grishanovich et al. propusieron clasificar ligninas mediante HCA a partir de espectros de RMN de alta resolución y RMN de estado sólido en núcleos de carbono 13 [18]. Lian et al. estudiaron características de desgasificación al vacío en materiales de encapsulado mediante un algoritmo híbrido de clustering [22]. Aunque los dominios son distintos, el principio es común: agrupar permite seleccionar unidades comparables, detectar variación de lote o apoyar decisiones de calidad.

En educación y logística aparecen usos complementarios. Fan et al. propusieron un algoritmo para agrupar aprendices en línea integrando autoencoder, Canopy y K-means, con el objetivo de extraer características y mejorar el análisis de comportamiento de estudiantes [23]. Wang y Hsu revisaron aplicaciones de IoT y métodos de análisis de datos en logística marítima, destacando el papel de la recolección y preprocesamiento de datos para optimizar procesos [21]. Estos trabajos muestran que el clustering jerárquico convive con otros algoritmos de agrupamiento y reducción de dimensión dentro de sistemas de análisis más amplios.

1.4.5. Desarrollos algorítmicos recientes

Las aplicaciones empíricas explican cómo se usa el clustering jerárquico; los trabajos algorítmicos muestran hacia dónde evoluciona. Monath et al. propusieron representaciones continuas de árboles en espacio hiperbólico para optimizar clustering jerárquico mediante gradiente, buscando superar limitaciones de métodos discretos [24]. Más tarde, presentaron un método aglomerativo

escalable para clustering jerárquico capaz de operar sobre volúmenes muy grandes de datos [26]. En otra línea, desarrollaron algoritmos en línea para clustering jerárquico que insertan datos de manera incremental y realizan reordenamientos no codiciosos limitados [27]. Estas propuestas responden a una dificultad clásica: los métodos jerárquicos pueden ser interpretables, pero su costo crece rápidamente con el tamaño de los datos.

Chien et al. abordaron el ajuste de métricas de árbol en datos ruidosos mediante denoising en espacios hiperbólicos [25]. Bakkelund formuló una función objetivo para clustering jerárquico de órdenes parciales probabilísticos y grafos acíclicos dirigidos, introduciendo restricciones de preservación de orden [28]. Arutyunova y Roglin estudiaron el precio de la jerarquía en problemas como k-center y k-diameter, mostrando que imponer una estructura jerárquica puede tener costos de aproximación frente a particiones óptimas no jerárquicas [29]. Estos trabajos recuerdan que una jerarquía es una representación poderosa, pero también una restricción.

Finalmente, Pach et al. presentaron CoHiClust, un modelo de clustering jerárquico contrastivo basado en redes profundas para datos de imagen, con visualización de nodos [30]. Este tipo de propuesta conecta la tradición del clustering jerárquico con aprendizaje profundo: la jerarquía ya no se construye únicamente sobre una matriz fija de distancias, sino sobre representaciones aprendidas. Sin embargo, la pregunta interpretativa persiste: qué significan los nodos, cómo se evalúa la calidad de la estructura y cuándo la jerarquía aporta más información que una partición plana.

1.5. Síntesis Comparativa

La Tabla 1.1 resume patrones de aplicación observados en la literatura. No pretende reemplazar la lectura de los artículos, sino mostrar cómo una misma técnica se adapta a diferentes unidades de análisis.

Tabla 1.1: Patrones de aplicación del clustering jerárquico en la literatura revisada

Dominio	Unidad de análisis	Uso del agrupamiento
Alimentos y consumidores	Preparaciones, especias, productos o consumidores	Comparar composición, actividad antioxidante y segmentos de preferencia [1, 3, 4].
Agua y ambiente	Muestras, sitios, regiones o meses	Relacionar grupos con calidad, contaminación, hidrogeoquímica, ozono o precipitación [5–9, 13, 17].
Salud y biociencias	Pacientes, categorías, perfiles proteómicos o movimientos	Descubrir subgrupos, evaluar perfiles clínicos o interpretar patrones de adaptación [2, 10, 11, 19].
Sensores, IoT y manufactura	Nodos, flujos, electrodos o materiales	Reducir redundancia, fusionar datos, controlar calidad y operar en datos continuos [15, 16, 20, 22].
Algoritmos y teoría	Árboles, grafos, métricas y datos masivos	Mejorar escalabilidad, optimización, preservación de orden y evaluación de jerarquías [24–30].

La comparación permite reconocer un patrón general. En estudios aplicados, el clustering jerárquico se usa para hacer visible una estructura latente. En estudios metodológicos, se usa como objeto de mejora: hacerlo más escalable, más robusto, más adecuado para datos no euclidianos

o más interpretable. En ambos casos, el valor de la técnica depende de conectar el resultado con una pregunta analítica. Por eso, la respuesta a la pregunta de investigación no es simplemente “se calcula un dendrograma”, sino “se diseña una representación de semejanza, se construye una jerarquía, se valida el nivel de agrupamiento y se interpreta cada grupo dentro de un dominio”.

1.6. Conclusiones

El clustering jerárquico se aplica en análisis de datos como un proceso de estructuración progresiva de semejanzas. Su flujo general incluye definir la unidad de análisis, seleccionar variables, preparar los datos, calcular distancias, elegir un criterio de enlace, construir el dendrograma, decidir el nivel de corte, validar los grupos e interpretarlos dentro del dominio. La técnica responde a la pregunta de investigación porque permite transformar datos multivariados en una jerarquía explicable de relaciones.

La literatura revisada confirma que el método es útil en contextos muy diversos: composición de alimentos, preferencias de consumidores, proteómica, calidad de aguas, precipitación, monitoreo atmosférico, salud, veterinaria, sensores, manufactura, educación, IoT y aprendizaje automático. En todos ellos, el aporte principal no es producir grupos por sí mismos, sino facilitar una lectura organizada de patrones que no estaban etiquetados previamente.

El capítulo también muestra que la aplicación responsable exige cuidado metodológico. La jerarquía depende de variables, escalas, distancias y criterios de enlace; por tanto, debe validarse y justificarse. En datos grandes, ruidosos, composicionales, continuos o sensibles, se requieren adaptaciones algorítmicas y consideraciones adicionales. Así, el clustering jerárquico sigue siendo una técnica vigente de IA clásica: interpretable, flexible y útil, siempre que se aplique como parte de un análisis riguroso y no como una operación mecánica.

Referencias

- [1] E. A. F. da Silva Torres, M. L. Garbelotti, and J. M. M. Neto, “The application of hierarchical clusters analysis to the study of the composition of foods,” *Food Chemistry*, vol. 99, pp. 622–629, 2006. DOI: 10.1016/j.foodchem.2005.08.032.
- [2] B. Meunier, E. Dumas, I. Piec, D. Béchet, M. Hébraud, and J. F. Hocquette, “Assessment of hierarchical clustering methodologies for proteomic data mining,” *Journal of Proteome Research*, vol. 6, pp. 358–366, 1 2007. DOI: 10.1021/pr060343h.
- [3] P. Varela, “Application of multivariate statistical methods during new product development: Case study: Application of principal component analysis and hierarchical cluster analysis on consumer liking data of orange juices,” in *Mathematical and Statistical Methods in Food Science and Technology* (D. Granato and G. Ares, eds.), ch. 11, pp. 187–199, John Wiley & Sons, Ltd., 2014.
- [4] M. B. Hossain, A. Patras, C. Barry-Ryan, A. B. Martin-Diana, and N. P. Brunton, “Application of principal component and hierarchical cluster analysis to classify different spices based on in vitro antioxidant activity and individual polyphenolic antioxidant compounds,” *Journal of Functional Foods*, vol. 3, pp. 179–189, 7 2011. DOI: 10.1016/j.jff.2011.03.010.
- [5] J. C. Egbueri, “Groundwater quality assessment using pollution index of groundwater (pig), ecological risk index (eri) and hierarchical cluster analysis (hca): A case study,” *Groundwater for Sustainable Development*, vol. 10, p. 100292, 4 2020. DOI: 10.1016/j.gsd.2019.100292.
- [6] N. S. Rao and M. Chaudhary, “Hydrogeochemical processes regulating the spatial distribution of groundwater contamination, using pollution index of groundwater (pig) and hierarchical cluster analysis (hca): A case study,” *Groundwater for Sustainable Development*, vol. 9, p. 100238, 10 2019. DOI: 10.1016/j.gsd.2019.100238.
- [7] F. M. El-Dars and H. M. Sami, “Interpretation of hydrogeochemical data using hierarchical cluster analysis: A case study at wadi el-natron, egypt,” *Journal of African Earth Sciences*, vol. 170, p. 103930, 10 2020. DOI: 10.1016/j.jafrearsci.2020.103930.
- [8] P. Ebrahimi, A. Guarino, V. Allocca, S. Caliro, R. Avino, E. Bagnato, F. Capecchiacci, A. Carandente, C. Minopoli, A. Santi, and S. Albanese, “Hierarchical clustering and compositional data analysis for interpreting groundwater hydrogeochemistry: The application to campi flegrei volcanic aquifer (south italy),” *Journal of Geochemical Exploration*, vol. 233, p. 106922, 2 2022. DOI: 10.1016/j.gexplo.2021.106922.
- [9] J. Cvejanov and B. D. Škrbić, “Application of principal component and hierarchical cluster analyses in the classification of serbian bottled waters and a comparison with waters from some other european countries,” *Journal of the Serbian Chemical Society*, vol. 82, pp. 711–721, 2017. DOI: 10.2298/JSC170219034C.
- [10] I. E. El-Araby, S. A. Moawed, F. A. Hassan, and H. F. Gouda, “A combined approach of multiple correspondence analysis and hierarchical cluster analysis for profiling relationships

- among categorical risk predictors: A bluetongue case study,” *Slov Vet Res*, vol. 60, pp. 307–315, 2023. DOI: 10.26873/SVR-1608-2022.
- [11] E. Paddenbergschubert, K. Midlej, S. Krohn, I. M. Lone, O. Zohud, O. Awadi, S. Masarwa, C. Kirschneck, N. Watted, P. Proff, and F. A. Iraqi, “Hierarchical clustering analysis & machine learning models for diagnosing skeletal classes i and ii in german patients,” *BMC Oral Health*, vol. 25, pp. 1–13, 12 2025. DOI: 10.1186/s12903-025-06063-6.
 - [12] J. A. Martín-Fernández, V. D. Donato, V. Pawlowsky-Glahn, and J. J. Egozcue, “Insights in hierarchical clustering of variables for compositional data,” *Mathematical Geosciences*, vol. 56, pp. 415–435, 4 2024. DOI: 10.1007/s11004-023-10115-4.
 - [13] S. Tajbar, A. Tajbar, Z. Pashaie, A. M. Khorshiddoust, and L. Rafiq, “Application of hierarchical cluster analysis to spatiotemporal variability of monthly precipitation over khyber pakhtunkhwa, pakistan,” *Acta Geophysica*, vol. 72, pp. 1159–1174, 4 2024. DOI: 10.1007/s11600-023-01161-x.
 - [14] C. Nordahl, V. Boeva, H. Grah, and M. Persson-Netz, “On evaluation of data stream clustering algorithms: A survey,” 8 2025. DOI: 10.1109/ACCESS.2025.3596435.
 - [15] A. Chowdhury, A. Pal, A. Raut, and M. Kumar, “Kihcdp: An incremental hierarchical clustering approach for iot data using dirichlet process,” *IEEE Access*, vol. 12, pp. 56019–56032, 4 2024. DOI: 10.1109/ACCESS.2024.3385628.
 - [16] D. Srinivasan, A. Kiran, S. Parameswari, and J. Vellaichamy, “Energy efficient hierarchical clustering based dynamic data fusion algorithm for wireless sensor networks in smart agriculture,” *Scientific Reports*, vol. 15, pp. 1–24, 12 2025. DOI: 10.1038/s41598-024-85076-7.
 - [17] C. S. Malley, C. F. Braban, and M. R. Heal, “The application of hierarchical cluster analysis and non-negative matrix factorization to european atmospheric monitoring site classification,” *Atmospheric Research*, vol. 138, pp. 30–40, 3 2014. DOI: 10.1016/j.atmosres.2013.10.019.
 - [18] I. Grishanovich, Y. Sypalova, S. Shestakov, and A. Kozhevnikov, “The application of hierarchical cluster analysis to lignins classification based on data of high resolution nmr and solid-state nmr spectra on ^{13}C nuclei,” 6 2024. DOI: 10.21203/rs.3.rs-4540243/v1.
 - [19] Y. Djafari, A. R. Arshi, and H. Rajabi, “Hierarchical clustering approach to movement smoothness and temporal adaptation in rhythmic step aerobics training in middle aged women,” *Scientific Reports*, vol. 15, pp. 1–14, 12 2025. DOI: 10.1038/s41598-025-19228-8.
 - [20] H. Qian, G. Moreira, D. Vanegas, Y. Tang, C. Pola, C. Gomes, E. McLamore, and N. Bliznyuk, “Improving high throughput manufacture of laser-inscribed graphene electrodes via hierarchical clustering,” *Scientific Reports*, vol. 14, pp. 1–11, 12 2024. DOI: 10.1038/s41598-024-57932-z.
 - [21] L. Wang and H. H. Hsu, “Iot technology in maritime logistics management: exploration of data analysis methods,” 12 2025. DOI: 10.1007/s43926-025-00167-9.
 - [22] X. Lian, J. Chen, and C. Duan, “Research on data analysis of vacuum outgassing characteristics of encapsulating materials based on hybrid clustering algorithm,” pp. 180–185, Association for Computing Machinery (ACM), 11 2025. DOI: 10.1145/3784013.3784041.
 - [23] D. Fan, L. Fan, F. Zhao, H. Sun, and X. Min, “An online learner clustering algorithm incorporating autoencoder and canopy-kmeans,” in *Proceedings of 2024 2nd International Conference on Information Education and Artificial Intelligence, ICIEAI 2024*, pp. 627–633, Association for Computing Machinery, Inc, 5 2025. DOI: 10.1145/3724504.3724608.

- [24] N. Monath, M. Zaheer, D. Silva, A. McCallum, and A. Ahmed, “Gradient-based hierarchical clustering using continuous representations of trees in hyperbolic space,” in *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 714–722, Association for Computing Machinery, 7 2019. DOI: 10.1145/3292500.3330997.
- [25] E. Chien, P. Tabaghi, and O. Milenkovic, “Hyperaid: Denoising in hyperbolic spaces for tree-fitting and hierarchical clustering,” in *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 201–211, Association for Computing Machinery, 8 2022. DOI: 10.1145/3534678.3539378.
- [26] N. Monath, K. A. Dubey, G. Guruganesh, M. Zaheer, A. Ahmed, A. McCallum, G. Mergen, M. Najork, M. Terzihan, B. Tjanaka, Y. Wang, and Y. Wu, “Scalable hierarchical agglomerative clustering,” in *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 1245–1255, Association for Computing Machinery, 8 2021. DOI: 10.1145/3447548.3467404.
- [27] N. Monath, M. Zaheer, and A. McCallum, “Online level-wise hierarchical clustering,” in *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 1733–1745, Association for Computing Machinery, 8 2023. DOI: 10.1145/3580305.3599455.
- [28] D. Bakkelund, “An objective function for order preserving hierarchical clustering,” *Machine Learning*, vol. 115, p. 107, 5 2026. DOI: 10.1007/s10994-026-07046-6.
- [29] A. Arutyunova and H. Röglin, “The price of hierarchical clustering,” *Algorithmica*, vol. 87, pp. 1420–1452, 10 2025. DOI: 10.1007/s00453-025-01327-7.
- [30] M. Pach, P. Rola, M. Znaleznia, P. Kaszuba, M. Przewiezlikowski, J. Tabor, and M. Śmieja, “Adaptive contrastive hierarchical clustering with nodes visualization,” *Artificial Intelligence Review*, vol. 59, pp. 1–27, 3 2026. DOI: 10.1007/s10462-026-11490-0.
- [31] K. Jung, S. Biswas, and C. Palamidessi, “Mitigating membership inference vulnerability in iterative federated clustering algorithm,” in *ARTMAN 2025 - Proceedings of the Workshop on Recent Advances in Resilient and Trustworthy MACHINE learning-driveN systems*, pp. 1–12, Association for Computing Machinery, Inc, 11 2025. DOI: 10.1145/3733821.3763022.
- [32] C. F. Loughrey, S. Maguire, P. Dłotko, L. Bai, N. Orr, and A. Jurek-Loughrey, “A novel method for subgroup discovery in precision medicine based on topological data analysis,” *BMC Medical Informatics and Decision Making*, vol. 25, pp. 1–15, 12 2025. DOI: 10.1186/s12911-025-02852-9.
- [33] W. Xie, S. Zhang, L. Wang, K. Yu, and W. Li, “Feature selection of microarray data using multidimensional graph neural network and supernode hierarchical clustering,” *Artificial Intelligence Review*, vol. 57, pp. 1–29, 3 2024. DOI: 10.1007/s10462-023-10700-3.
- [34] S. Li, T. Li, and D. Ruan, *Proceedings 2008 3rd international conference on intelligent system and knowledge engineering : Nov. 17-19, 2008, Xiamen, China*. IEEE Press, 2008.