

Nombre: Francis Valdiviezo

Plantilla para la Descripción del Problema Técnico

1. Contexto general del problema

Contexto general del problema La investigación presentada se enmarca dentro del área de los Sistemas Inteligentes y la Minería de Datos (Data Mining), con un enfoque central en el desarrollo, optimización y evaluación de algoritmos de aprendizaje automático no supervisado, específicamente las técnicas de clustering [1], [2], [3] . El entorno donde se desarrollan y aplican estos algoritmos es altamente diverso y abarca múltiples escenarios: el entorno educativo, mediante el análisis del comportamiento de estudiantes en plataformas de aprendizaje en línea (MOOCs) [4]; el sector industrial y de ingeniería de materiales, a través de la evaluación de características físicas de aleaciones para componentes [3]; los entornos de redes descentralizadas que requieren un aprendizaje colaborativo protegiendo la privacidad de los usuarios [5]; y los entornos tecnológicos del Internet de las Cosas (IoT), donde redes de sensores generan flujos masivos, continuos y cambiantes de datos [2].

2. Situación actual basada en evidencia

La literatura indica que los algoritmos de clustering clásicos requieren modificaciones sustanciales para operar en los escenarios dinámicos y de alta dimensionalidad actuales, lo que ha impulsado el desarrollo de métodos híbridos, federados e incrementales. Diversos estudios han propuesto soluciones adaptativas, tales como la incorporación de redes Autoencoder para reducir la dimensionalidad y evitar la aleatoriedad en el agrupamiento de estudiantes [4], así como el uso del Proceso de Dirichlet para adaptar progresivamente las estructuras de datos en el IoT sin necesidad de predefinir el número de clústeres [2]. Asimismo, se ha evidenciado que el clustering permite reemplazar la toma de decisiones empírica por métodos guiados por datos en la manufactura de materiales [3], y que, mediante el Aprendizaje Federado Personalizado, es posible equilibrar el rendimiento de los modelos matemáticos con la protección de los usuarios frente a ataques de inferencia de membresía (MIA) [5]. Sin embargo, a pesar de estos avances, los estudios detectan limitaciones considerables: los modelos incrementales probabilísticos enfrentan altos tiempos de ejecución ante derivas extremas de información y asumen pérdida de datos al aplicar técnicas de reducción [2]; los entornos de privacidad federada pueden causar una degradación del rendimiento por "sobreconcentración" en grupos mayoritarios y dependen de servidores cien por ciento confiables [5]; y los modelos aplicados a la manufactura de materiales se limitan a clasificar, careciendo de funciones de predicción futura integradas [3].

3. Brecha o vacío identificado

A partir de la evidencia, se identifica una brecha crítica respecto a la falta de consenso y estandarización en las metodologías de evaluación de los algoritmos de clustering, particularmente en el análisis de flujos de datos [1]. Los autores señalan explícitamente que el desarrollo del área se ha concentrado casi de manera exclusiva en medir el rendimiento computacional (tiempo de ejecución) y la exactitud pura, marginando la evaluación real de la "calidad" cualitativa de los clústeres producidos (como su compacidad estructural y separación) [1]. Adicionalmente, esta deficiencia metodológica se agrava por el uso frecuente de bases de datos sintéticas o anómalas (como el dataset KDD-CUP'99) que inflan artificialmente las puntuaciones de pureza, dejando un vacío importante en la disponibilidad de catálogos de evaluación sistemáticos y conjuntos de datos reales en forma de flujos ininterrumpidos [1].

4. Problema central

La ausencia de metodologías de evaluación estandarizadas y de métricas orientadas a medir la calidad cualitativa de las estructuras en los algoritmos de clustering de flujos de datos impide la comparación sistemática de los modelos, facilitando resultados analíticos inflados que limitan una validación tecnológica rigurosa frente a los retos de escalabilidad, derivas de concepto y privacidad.

5. Consecuencias o impacto

El problema de la falta de evaluación cualitativa rigurosa y las limitaciones en la adaptabilidad de los algoritmos de clustering generan múltiples efectos negativos comprobables en la literatura:

- Resultados engañosos e inflación de la precisión en la investigación: Debido a que la evaluación se centra casi exclusivamente en métricas de corrección (como la pureza) y utiliza conjuntos de datos anómalos como el KDD-CUP'99 (cuyos subconjuntos a veces contienen un solo tipo de clase), los algoritmos obtienen puntuaciones artificialmente altas. Esto crea una falsa sensación de precisión y oculta la verdadera calidad estructural de los clústeres producidos [1].
- Degradación del rendimiento en grupos minoritarios: En entornos de aprendizaje federado, la necesidad de equilibrar la precisión con la protección frente a Ataques de Inferencia de Membresía (MIA) provoca que los clientes con mayor sensibilidad a la privacidad migren hacia clústeres mayoritarios. Esta sobreconcentración reduce drásticamente los datos disponibles para entrenar modelos minoritarios, degradando su precisión a niveles potencialmente inaceptables [5].
- Cuellos de botella computacionales en sistemas en tiempo real: Los algoritmos que no aplican técnicas eficientes de reducción de datos (como la eliminación selectiva por funciones kernel) exigen tiempos de ejecución prolongados y sufren de un colapso en la memoria a medida que el flujo de datos crece infinitamente, afectando la eficiencia de los dispositivos de borde [2].

- Limitaciones en la toma de decisiones predictivas: Al aplicar clustering en entornos industriales (como la evaluación de aleaciones de níquel), la ausencia de modelos predictivos integrados restringe a las organizaciones a simplemente clasificar la información actual, sin poder proyectar de forma inteligente los resultados cuando cambian los parámetros de fabricación en el futuro [3].

6. Actores involucrados

Los principales actores afectados por estas deficiencias o involucrados en los entornos de aplicación son:

- Investigadores y desarrolladores de algoritmos: Son los actores primarios que sufren la falta de un catálogo o consenso estandarizado ("benchmark") para evaluar y comparar de forma justa y rigurosa los algoritmos desarrollados [1].
- Dispositivos de borde (Edge) y sistemas IoT: Actores tecnológicos (sensores de turbinas, monitores de agua, dispositivos de red) con poder computacional y memoria limitados, que se ven directamente afectados por la eficiencia y la carga de procesamiento de los modelos de agrupamiento en tiempo real [2].
- Usuarios de redes federadas (Grupos mayoritarios y minoritarios): Clientes cuyas bases de datos personales se utilizan para el aprendizaje colaborativo. Son vulnerables a ataques de privacidad (MIA) dependiendo del tamaño de su clúster de datos [5].
- Estudiantes en línea e instituciones educativas: Actores en plataformas MOOC cuyos perfiles de comportamiento son analizados para recibir enseñanza personalizada [4].
- Industria de manufactura y empaquetado: Organizaciones que dependen del análisis de materiales para optimizar componentes críticos (como detectores infrarrojos para uso civil o aeroespacial) [3].

7. Variables o elementos clave

Los conceptos técnicos y estadísticos centrales que rigen el problema son:

- Índices de Validación de Clústeres (CVIs e iCVIs): Medidas externas (Pureza, Índice Rand Ajustado - ARI, Accuracy) e internas (Índice de Silueta - SI, Suma de errores cuadrados - SSQ, Índice de Davies-Bouldin) utilizadas para auditar los clústeres [3], [4].
- Deriva de concepto (Concept Drift): Fenómeno donde la distribución y estructura subyacente de los datos fluyentes evolucionan y cambian con el tiempo (e.g., derivas súbitas, graduales o recurrentes) [1].
- Modelos de Ventana de Tiempo (Time Window Models): Mecanismos técnicos (ventanas deslizantes, atenuadas/damped, de hitos o ladeadas) empleados para que el algoritmo filtre datos históricos y se enfoque en el comportamiento reciente del flujo [1].

- Riesgo de Inferencia de Membresía (MIA Risk): Métrica de vulnerabilidad a la privacidad que evalúa la probabilidad de que un atacante identifique si un punto de datos específico fue usado para entrenar un modelo [5].
- Vectores de Características de Clúster (CF Vectors) y Micro-clústeres: Estructuras de datos que resumen estadísticamente la información entrante para evitar almacenar los datos en bruto en la memoria principal [1].

8. Delimitación del problema

El problema se delimita estrictamente al ámbito de los algoritmos de aprendizaje automático no supervisado (clustering) diseñados para procesar conjuntos de datos no estacionarios (flujos de datos dinámicos/data streams) y entornos de alta dimensionalidad o distribuidos (sistemas IoT y aprendizaje federado).

- Qué incluye: La evaluación de estructuras jerárquicas y particionales (K-means, BHC, BIRCH), el análisis de la calidad de micro-clústeres y macro-clústeres, la mitigación de vulnerabilidades de privacidad asociadas al fraccionamiento de los datos, y el control del consumo de memoria temporal mediante resúmenes matemáticos.
- Qué excluye: Quedan fuera de este problema las técnicas de aprendizaje supervisado (como clasificación estricta con datos totalmente etiquetados desde el origen), la resolución de arquitecturas de hardware físico, y el análisis algorítmico sobre bases de datos relacionales estáticas tradicionales de pequeña escala que no presenten problemas de velocidad computacional o evolución temporal.

9. Vinculación con la sublínea de investigación

El problema se vincula directamente con la sublínea de investigación de Minería de Datos de Flujos (Data Stream Mining) y Aprendizaje Automático No Supervisado.

Justificación: Los documentos se inscriben explícitamente en el campo de la "extracción de conocimientos a partir de flujos de datos en tiempo real" [1]. Las técnicas analizadas, tales como la construcción de árboles de decisiones de Dirichlet, Autoencoders para la reducción de dimensionalidad, métodos de partición K-means y algoritmos híbridos de Machine Learning [1], [3], pertenecen al núcleo técnico de los Sistemas Inteligentes y la Ciencia de Datos. La necesidad de adaptar los modelos estadísticos de manera estocástica al entorno cambiante sin intervención humana clasifica esta problemática como un desafío central para la evolución de la Inteligencia Artificial aplicada [2], [5].

Recomendaciones didácticas

- Redactar en tercera persona y en tiempo presente.
- Sustentar con al menos 3–5 referencias científicas recientes (Scopus/IEEE).

- Evitar ambigüedades y generalizaciones.
- Asegurar coherencia entre problema, objetivos y metodología.

Referencias

- [1] C. Nordahl, V. Boeva, H. Grahn, and M. Persson-Netz, “On Evaluation of Data Stream Clustering Algorithms: A Survey,” Aug. 03, 2025, *Institute of Electrical and Electronics Engineers Inc., Karlskrona, Sweden*. doi: 10.1109/ACCESS.2025.3596435.
- [2] A. Chowdhury, A. Pal, A. Raut, and M. Kumar, “KIHCDP: An Incremental Hierarchical Clustering Approach for IoT Data Using Dirichlet Process,” *IEEE Access*, vol. 12, pp. 56019–56032, Apr. 2024, doi: 10.1109/ACCESS.2024.3385628.
- [3] X. Lian, J. Chen, and C. Duan, “Research on Data Analysis of Vacuum Outgassing Characteristics of Encapsulating Materials Based on Hybrid Clustering Algorithm,” Jinan, China: Association for Computing Machinery (ACM), Nov. 2025, pp. 180–185. doi: 10.1145/3784013.3784041.
- [4] D. Fan, L. Fan, F. Zhao, H. Sun, and X. Min, “An Online Learner Clustering Algorithm Incorporating Autoencoder and Canopy-Kmeans,” in *Proceedings of 2024 2nd International Conference on Information Education and Artificial Intelligence, ICIEAI 2024*, Kaifeng, China: Association for Computing Machinery, Inc, May 2025, pp. 627–633. doi: 10.1145/3724504.3724608.
- [5] K. Jung, S. Biswas, and C. Palamidessi, “Mitigating Membership Inference Vulnerability in Iterative Federated Clustering Algorithm,” in *ARTMAN 2025 - Proceedings of the Workshop on Recent Advances in Resilient and Trustworthy Machine learning-driveN systems*, Taiwan: Association for Computing Machinery, Inc, Nov. 2025, pp. 1–12. doi: 10.1145/3733821.3763022.