



Universidad
Nacional
de Loja

Universidad Nacional de Loja

Facultad de la Energía, las Industrias y los Recursos Naturales
No Renovables

Carrera de Computación

Clustering jerárquico en flujos de datos continuos:
análisis estructural, aplicación incremental y
evaluación comparativa.

Hierarchical Clustering in Continuous Data Streams:
Structural Analysis, Incremental Application, and
Comparative Evaluation.

Metodología de la Investigación en
Computación.

AUTOR:

Francis Josue Valdiviezo Jimenez

TUTOR:

Prof. Luis Chamba-Eras

Loja, Ecuador

2026

Declaración de uso de IA Generativa

Yo, **Francis Josue Valdiviezo Jimenez**, en calidad de autor, declaro de manera transparente y responsable el uso de herramientas de Inteligencia Artificial Generativa (IAG) durante el desarrollo del presente trabajo, en conformidad con los principios de integridad académica, ética investigativa y buenas prácticas en el uso de tecnologías emergentes.

1. Alcance del uso de IA generativa

El uso de herramientas de IAG se ha limitado a funciones de apoyo, sin sustituir el juicio crítico ni la autoría intelectual del autor. En particular, se han utilizado para:

- Mejora de redacción y estilo académico.
- Generación de ideas preliminares.
- Apoyo en la estructuración del documento.
- Asistencia en traducción técnica.

2. Clasificación del uso según GAIDeT

De acuerdo con la taxonomía GAIDeT, el uso de IA generativa en este trabajo se clasifica en:

- **Nivel 1 – Asistencia Lingüística:** Corrección gramatical y mejora de claridad.
- **Nivel 2 – Apoyo en Ideación:** Generación de ideas y esquemas conceptuales.
- **Nivel 3 – Asistencia Técnica:** Apoyo en generación de código y explicaciones técnicas.

No se ha utilizado IA generativa para la generación autónoma de resultados ni para sustituir el análisis crítico del autor.

3. Validación y responsabilidad

Todo contenido asistido por IA ha sido revisado, validado y adaptado por el autor, quien asume la responsabilidad total sobre la calidad, veracidad y originalidad del trabajo.

4. Herramientas utilizadas

Se emplearon modelos de lenguaje (LLMs) de google NoteboonLM, Gemini 3.1 pro, ChatGPT 5.2 y herramientas de asistencia técnica para redacción, estructuración y apoyo conceptual.

5. Consideraciones éticas

El uso de IA se realizó respetando principios de honestidad académica, normativas institucionales de la Universidad Nacional de Loja y buenas prácticas internacionales.

6. Declaración final

Declaro que el uso de IA generativa ha sido ético, transparente y complementario, sin comprometer la autoría ni la integridad académica del presente trabajo.

Loja, Ecuador, [Fecha]

Francis Josue Valdiviezo Jimenez

Autor

Índice General

Declaración de uso de IA Generativa	1
1 Título	5
2 Desarrollo	6
Referencias bibliográficas	18

Índice de Tablas

2.1	Matriz de Investigación de Clustering Jerárquico	7
-----	--	---

1. Título

Clustering jerárquico en flujos de datos continuos: análisis estructural, aplicación incremental y evaluación comparativa.

2. Desarrollo

Desarrollo de las preguntas de investigacion y objetivos generales y especificos.

Tabla 2.1: Matriz de Investigación de Clustering Jerárquico

Tipo de Investigación	Pregunta de Investigación	Objetivo General	Objetivos Específicos
1. Investigación Descriptiva	¿Cuáles son las características estructurales y los mecanismos de resumen de datos que definen la implementación de algoritmos de clustering jerárquico, tales como el árbol de características (CF Tree) de BIRCH y los modelos estocásticos del Clustering Jerárquico Bayesiano (BHC), en el procesamiento de flujos de datos continuos?	Caracterizar las estructuras y mecanismos de resumen de datos utilizados en algoritmos de clustering jerárquico, específicamente en modelos como BIRCH y Clustering Jerárquico Bayesiano, en el contexto del procesamiento de flujos de datos continuos.	1. Identificar las estructuras jerárquicas utilizadas en los algoritmos BIRCH y BHC, considerando su organización y representación de datos. 2. Describir los mecanismos de resumen de datos empleados (como el CF Tree y modelos probabilísticos), analizando su funcionamiento interno. 3. Analizar la relación entre las estructuras jerárquicas y la eficiencia en el procesamiento de flujos de datos continuos, en términos de uso de memoria y capacidad de actualización incremental.
2. Investigación Aplicada	¿De qué manera la implementación de un enfoque de clustering jerárquico incremental, apoyado en Procesos de Dirichlet, permite solucionar la degradación del rendimiento por deriva de concepto y optimizar el consumo de memoria en el análisis en tiempo real de flujos masivos generados por dispositivos IoT?	Implementar un modelo de clustering jerárquico incremental basado en Procesos de Dirichlet para mejorar el rendimiento y optimizar el uso de memoria en el análisis de flujos de datos generados por dispositivos IoT.	1. Diseñar un modelo de clustering jerárquico incremental que incorpore Procesos de Dirichlet para el tratamiento de datos dinámicos. 2. Aplicar el modelo propuesto en un entorno de datos simulados o reales provenientes de dispositivos IoT. 3. Evaluar el desempeño del modelo en términos de adaptación a la deriva de concepto y consumo de memoria durante el procesamiento continuo de datos.
3. Investigación Experimental	¿Cuál es el impacto en los niveles de precisión (medidos mediante el Índice Rand Ajustado) y en los tiempos de ejecución computacional al evaluar un modelo de clustering jerárquico incremental (KIHCDP) frente a algoritmos de partición tradicionales (como K-Means) bajo condiciones de inyección continua de datos con distribuciones dinámicas?	Comparar el rendimiento de un modelo de clustering jerárquico incremental frente a algoritmos de partición tradicionales, evaluando su precisión y eficiencia computacional en entornos de datos dinámicos.	1. Implementar los algoritmos de clustering jerárquico incremental y K-Means bajo condiciones controladas de flujo de datos dinámicos. 2. Medir la precisión de los modelos mediante métricas cuantitativas como el Índice Rand Ajustado. 3. Analizar los tiempos de ejecución y la eficiencia computacional de cada algoritmo bajo diferentes volúmenes de datos.

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
1	[1]	2025	IEEE	Estudio analítico (Survey) de algoritmos de clustering para flujos de datos (Data Stream Clustering) e Índices de Validación de Clústeres (CVIs)	La ausencia de una metodología estandarizada sobre cómo evaluar algoritmos de clustering de flujos de datos; la comunidad se ha enfocado en métricas de rendimiento, marginando la calidad cualitativa del clúster	Revisar la literatura desde la aparición de BIRCH para identificar metodologías, datasets y medidas utilizadas; proveyendo recomendaciones para mejores enfoques y métricas internas estandarizadas	Revisión sistemática de literatura (Survey). Clasifica y audita cómo los creadores de algoritmos de clustering prueban sus modelos. Evalúa ventanas de tiempo y compila el inventario de CVIs internos y externos	Analiza cómo se evalúan bases de datos dinámicas en IA; evidencia el uso masivo de generadores de corrientes sintéticas (MOA, River) y bases reales KDD-CUP'99 y Covertype	El área solo mide velocidad del hardware y precisión pura, olvidando la “calidad real” de cómo se estructuran los clústeres. Métricas como “Pureza Promedio” pueden engañar; KDD-CUP'99 favorece inflación de puntajes	Las metodologías actuales omiten evaluar la calidad real de los clústeres, limitándose a medir precisión y velocidad computacional	Expone carencias en estándares de validación. Insta a usar métricas iCVI (índices incrementales) y propone un “Catálogo mundial de Evaluación” (benchmark sistemático) para algoritmos orientados al streaming

Continúa en la siguiente página. . .

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
2	[2]	2019	ACM	Clustering jerárquico hiperbólico basado en gradiente (gHHC) en bola de Poincaré	La discretización limita la optimización end-to-end en clustering jerárquico tradicional	Proponer un enfoque de optimización por gradientes con representación continua de árboles en espacio hiperbólico	Cada nodo = vector continuo; costo conjunto optimizado; gradientes mueven nodos internos del árbol	Glass, Digits, Spambase, CovType, ALOI, ImageNet; multitarea (139 escuelas) y GloVe	Supera a PERCH en pureza de dendrograma (DP); +15 puntos en ImageNet	Sin ganador claro en CovType/Spambase; nodos no usados requieren poda post-hoc	Optimización end-to-end dentro de otras tareas (ej. regularización multitarea) sin decisiones rígidas
3	[3]	2021	ACM	Clustering Continuo Escalable (SCC)	Los métodos continuos tradicionales no escalan a miles de millones de consultas web	Desarrollar SCC altamente escalable para bases de datos gigantescas	Comparación con Affinity Clustering y SerialDP-Means; evaluación cualitativa humana	CovType, Speaker, ALOI, ILSVRC; 30 mil millones de consultas web	SCC generó clústeres más precisos; 80 % de coherencia vs 65.7 % de Affinity	F1 no significativa en CovType; evaluación final solo entre SCC y Affinity por tamaño	Aplica clustering jerárquico a 30 mil millones de consultas infiriendo jerarquías lógicas en tiempo real

Continúa en la siguiente página...

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
4	[4]	2022	ACM	HyperAid: reducción de hiperbolicidad de Gromov + denoising hiperbólico	El ruido en métricas de entrada degrada el ajuste de árboles en clustering jerárquico	Proponer el primer enfoque de eliminación de ruido en espacio hiperbólico como paso previo al clustering	Encoder-decoder: métrica arbitraria → denoising → métrica de árbol “suave” → decodificador (NJ, TreeRep)	Sintéticos y UCI: Zoo, Iris, Glass, Segmentation, SpamBase	Supera a NJ, TreeRep, T-REX; mejora promedio sobre NJ del 125.94 %	T-REX solo probado en datasets pequeños por falta de código abierto	Primera herramienta de preprocesamiento hiperbólico que reduce ruido antes de cualquier decodificador jerárquico
5	[5]	2023	ACM	Clustering online por niveles (Online RecipNN, Affinity, SCC) con beam search y NN-Descent	Equilibrar eficiencia y precisión en entornos online donde los datos llegan incrementalmente	Desarrollar algoritmos online que mantengan alta precisión reordenando la estructura con nuevos datos	Grafo de vecinos cercanos por nivel; al llegar un dato se actualizan relaciones parentales propagando cambios de abajo arriba	ALOI, Speaker, ILSVRC, CIFAR100 (con EfficientNet-L2)	Online SCC y Affinity superan a URRH, SG Tree, Cover Tree y Grinch en DP y Jaccard	Online RecipNN es muy lento en CIFAR (2036.98 s); anidamiento desventajoso en métodos top-down	Mecanismo nivel por nivel que reestructura árboles jerárquicos en flujos continuos, sin reentrenamiento completo

Continúa en la siguiente página. . .

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
6	[6]	2024	Springer	GNN multi-dimensional, predicción de enlaces, clustering espectral de supernodos, hierarchical graph pooling	Datos de microarrays con alta dimensión genética y pocas muestras; métodos actuales no explotan interdependencias genéticas	Desarrollar un algoritmo de selección de características basado en GNN multi-dimensional para capturar interacciones y descubrir biomarcadores	Construye grafo multidimensional; mejora con predicción de enlaces; filtrado grueso con supernodos (clustering espectral); filtrado fino con clustering jerárquico por submuestreo	Nueve datasets de cáncer de GEO: ALL2, DLBCL, Leukemia, Prostate, CNS, Myeloma	Superior a clásicos y GNN avanzados; reduce parámetros y captura conexiones de alto orden	No se aborda explícitamente en los fragmentos disponibles	GNNs multi-dimensionales + clustering espectral jerárquico de supernodos para representaciones end-to-end en datos biológicos pequeños y de extrema dimensionalidad

Continúa en la siguiente página...

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
7	[7]	2026	Springer	CoHiClust (contras- tative HC auto- supervisado + Co- HiGAN (GAN condicio- nal)	Deep clus- tering dominado por modelos planos; falta de jerarquías visualmente explicables sin etiquetas	Desarrollar Co- HiClust para destilar una red base en árbol binario sin etiquetas, y CoHiGAN para visualización generativa de nodos	Red base + cabeza de pro- yección; pérdi- da contrastiva con aumentos automáticos; poda/división; CoHiGAN ge- nera imágenes de nodos inter- nos	MNIST, F- MNIST, CIFAR- 10/100, STL- 10, ImageNet- 10, TinyIma- geNet, AFHQ	Jerarquías lógicas; me- jor ACC, NMI, ARI que métodos planos (CC, PICA); ViT pre-entrenadas mejoran	Gran dife- rencia de rendimiento entre MNIST y F-MNIST (ropa más de- safiante que dígitos)	Acopla clus- tering contras- tivo profundo con GANs pa- ra que la IA explique visual- mente qué con- ceptos agrupa cada rama
8	[8]	2026	Springer	HC aglo- merativo con pre- servación de orden, optimiza- ción bi- objetivo, aproxi- mación polino- mial	Falta de fun- ción objetivo y teoría para clustering je- rárquico que preserve orden en órdenes par- ciales y DAGs	Proponer una teoría con fun- ción objetivo bi-objetivo que combine similitud y pre- servación de orden	Función de valor = combi- nación convexa de similitud (val_s) y or- den (val_g) con parámetro α ; optimali- dad de Pareto; algoritmo de aproximación; prueba de Wil- coxon	Órdenes par- ciales aleato- rios (Erdős- Rényi) y da- tos reales de piezas de ma- quinaria con relaciones “parte de”	Árboles con val_ α supe- ran a enlace completo, espe- cialmente con ruido/varianza altos	Óptimo ma- temático es NP-duro; no hay α canó- nico; requiere experto de dominio para calibrar	Función ma- temática que optimiza den- drogramas ase- gurando reglas de ascenden- cia (DAGs) mientras agru- pa entidades similares

Continúa en la siguiente página. . .

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
9	[9]	2024	Springer	HC aglomerativo en modo R con Ward y transformaciones log-ratio (clr, olr)	Aplicar HC directamente a datos composicionales (proporciones) viola la geometría del simplex	Explorar conexiones entre distancia de Aitchison, representantes de clúster, bi-plots y bases log-ratio para CoDa	Matriz de variación y distancias de Aitchison; comparación de 4 métodos (simple, completo, promedio, Ward) con ARI y NMI	Foraminíferos bentónicos (13–22 variables, 107 muestras) del Mediterráneo (Holoceno y Glacial Tardío)	Ward y promedio tienen alta coincidencia (ARI=0.876); Ward consistente con ecología real	Enlace simple sufre “efecto cadena”; enlace completo presenta peor NMI	Justifica teóricamente la aplicación de jerarquías sobre matrices log-ratio para reducción de dimensionalidad en sistemas cerrados o datos composicionales
10	[10]	2025	BioMed Central	HC con Ward + modelos supervisados (RF, KNN, SVM, LDA, CART, GLM)	Clasificación de clases esqueléticas (I/II) con ecuaciones cefalométricas que fallan en casos límite	Desarrollar modelos de ML y HC para diagnosticar con mínimos parámetros cefalométricos	HC con distancias euclidianas; evaluación de 6 modelos; reducción a 3 variables clave (SNA, SNB, Wits) por step-wise forward e importancia de RF	556 pacientes ortodónticos alemanes: 210 clase I, 346 clase II	CART 100 % exactitud con todos los parámetros; GLM 99.48 % solo con SNA, SNB y Wits	Solo pacientes alemanes (no generalizable étnicamente); heterogeneidad de tamaños de subgrupos	ML (GLM, KNN) supera ecuaciones tradicionales con solo 3 parámetros, ahorrando tiempo al ortodontista

Continúa en la siguiente página...

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
11	[11]	2025	BioMed Central	TDA (Mapper) + agrupamiento aglomerativo de enlace simple para detección automatizada de hotspots	Selección manual de parámetros en Mapper es lenta y requiere alto conocimiento matemático	Automatizar la detección de hotspots usando TDA para estratificar datos genómicos sin intervención manual	Funciones lente con subconjuntos aleatorios; construcción de grafo Mapper; agrupamiento aglomerativo que compara heterogeneidad de comunidad vs vecindario	Cáncer de mama (METABRIC y TCGA) en pacientes ER+ con mal pronóstico	Filtra automáticamente genes hasta una firma biológica relevante; discrimina subgrupos homogéneos de mal pronóstico	No se establece causalidad; requiere validación en otros cánceres con datos multi-ómicos	Automatiza TDA Mapper en contextos clínicos, eximiendo al médico de búsquedas manuales de parámetros para hallar anomalías genéticas
12	[12]	2024	Nature Portfolio	HC (denodrogramas/mapas de calor) + PCA para control estadístico de calidad	Alta variabilidad en fabricación de electrodos de grafeno inducido por láser (LIG) para biosensores	Desarrollar un flujo de trabajo estadístico y de agrupamiento para control de calidad riguroso que seleccione lotes funcionales	Extracción de curvas de voltametría cíclica (CV); umbral de convergencia; HC por similitud de curvas; evaluación final con PCA	6 conjuntos de curvas CV de biosensores aptaméricos con LIG de dos universidades	Selección algorítmica reduce desviación estándar en un 13 % frente a selección por experto humano	Funciona bien intralote; no combinar datasets de distintos laboratorios sin modelos de efectos mixtos	Primer flujo de trabajo estructurado con clustering para control de calidad industrial de grafeno en biosensores

Continúa en la siguiente página...

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
13	[13]	2025	Nature Portfolio	Fusión dinámica basada en HC + Algoritmos Genéticos (selección de cabezales) + ELM incremental	Ineficiencia energética y baja precisión en redes de sensores inalámbricos (WSN) en agricultura	Desarrollar un marco jerárquico inteligente que organice nodos, optimice recursos y prolongue vida útil	HC para dividir nodos; GA para elegir cabezales de clúster; fusión dinámica intra-clúster; ELM incremental para clasificación y detección de anomalías sin reentrenamiento completo	Monitoreo ambiental en fincas: temperatura, humedad, pH, luz, humedad suelo, precipitaciones	Precisión 97.89 %, recall 96.78 %, F1 96.45 %; supera a LR, DT, GNB	ELM base requiere alto cómputo; consistencia en entornos ruidosos sigue siendo un reto	Solución escalable única (HC + fusión dinámica + ELM incremental) para agricultura inteligente, compensando restricciones de potencia
14	[14]	2025	Nature Portfolio	HC con enlace de Ward + Transformada Wavelet Continua (CWT)	Deterioro neurológico de control motor en mujeres de mediana edad; impacto del entrenamiento con paso inverso inexplorado	Evaluar adaptaciones en suavidad de movimiento y agrupar patrones motores mediante HC	24 sesiones monitorizadas con IMU 3D; extracción de pasos con CWT; métricas: stance-to-swing ratio y jerk cost; clustering Ward sin predefinir k	9 mujeres de mediana edad (promedio 53.38 años), ejecutando pasos adelante/atrás con metrónomo	Alteración dramática en el 3er paso (1er paso atrás); movimientos más suaves de sesión 12 a 24; Rand Index=0.727	Muestra pequeña (n=9) por pandemia; sin validación simultánea con sistema óptico Vicon	El clustering segmenta la readaptación neurológica en rutinas rehabilitadoras; caminar hacia atrás ofrece alto potencial para prevenir caídas

Continúa en la siguiente página. . .

[illegible]

Este parrafo esta encargado de cargar las citas y asignarlas un numero de referncia.
[16].

El uso de referencias IEEE permite trazabilidad científica [17]. [18] [19] [1]

Referencias bibliográficas

- [1] C. Nordahl, V. Boeva, H. Grahm, and M. Persson-Netz, “On evaluation of data stream clustering algorithms: A survey,” pp. 139 524–139 546, 8 2025. [Online]. Available: <https://doi.org/10.1109/ACCESS.2025.3596435>
- [2] N. Monath, M. Zaheer, D. Silva, A. McCallum, and A. Ahmed, “Gradient-based hierarchical clustering using continuous representations of trees in hyperbolic space,” in *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. Association for Computing Machinery, 7 2019, pp. 714–722.
- [3] N. Monath, K. A. Dubey, G. Guruganesh, M. Zaheer, A. Ahmed, A. McCallum, G. Mergen, M. Najork, M. Terzihan, B. Tjanaka, Y. Wang, and Y. Wu, “Scalable hierarchical agglomerative clustering,” in *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. Association for Computing Machinery, 8 2021, pp. 1245–1255. [Online]. Available: <https://doi.org/10.1145/3447548.3467404>
- [4] E. Chien, P. Tabaghi, and O. Milenkovic, “Hyperaid: Denoising in hyperbolic spaces for tree-fitting and hierarchical clustering,” in *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. Association for Computing Machinery, 8 2022, pp. 201–211.
- [5] N. Monath, M. Zaheer, and A. McCallum, “Online level-wise hierarchical clustering,” in *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. Association for Computing Machinery, 8 2023, pp. 1733–1745. [Online]. Available: <https://doi.org/10.1007/s10462-026-11490-0>
- [6] W. Xie, S. Zhang, L. Wang, K. Yu, and W. Li, “Feature selection of microarray data using multidimensional graph neural network and supernode hierarchical clustering,” *Artificial Intelligence Review*, vol. 57, pp. 1–29, 3 2024. [Online]. Available: <https://doi.org/10.1007/s10462-023-10700-3>

- [7] M. Pach, P. Rola, M. Znalezniak, P. Kaszuba, M. Przewiezlikowski, J. Tabor, and M. Śmieja, “Adaptive contrastive hierarchical clustering with nodes visualization,” *Artificial Intelligence Review*, vol. 59, pp. 1–27, 3 2026. [Online]. Available: <https://doi.org/10.1007/s10462-026-11490-0>
- [8] D. Bakkelund, “An objective function for order preserving hierarchical clustering,” *Machine Learning*, vol. 115, p. 107, 5 2026. [Online]. Available: <https://link.springer.com/10.1007/s10994-026-07046-6>
- [9] J. A. Martín-Fernández, V. D. Donato, V. Pawlowsky-Glahn, and J. J. Egozcue, “Insights in hierarchical clustering of variables for compositional data,” *Mathematical Geosciences*, vol. 56, pp. 415–435, 4 2024. [Online]. Available: <https://doi.org/10.1007/s11004-023-10115-4>
- [10] E. Paddenbergschubert, K. Midlej, S. Krohn, I. M. Lone, O. Zohud, O. Awadi, S. Masarwa, C. Kirschneck, N. Watted, P. Proff, and F. A. Iraqi, “Hierarchical clustering analysis & machine learning models for diagnosing skeletal classes i and ii in german patients,” *BMC Oral Health*, vol. 25, pp. 1–13, 12 2025. [Online]. Available: <https://doi.org/10.1186/s12903-025-06063-6>
- [11] C. F. Loughrey, S. Maguire, P. Dłotko, L. Bai, N. Orr, and A. Jurek-Loughrey, “A novel method for subgroup discovery in precision medicine based on topological data analysis,” *BMC Medical Informatics and Decision Making*, vol. 25, pp. 1–15, 12 2025. [Online]. Available: <https://doi.org/10.1186/s12911-025-02852-9>
- [12] H. Qian, G. Moreira, D. Vanegas, Y. Tang, C. Pola, C. Gomes, E. McLamore, and N. Bliznyuk, “Improving high throughput manufacture of laser-inscribed graphene electrodes via hierarchical clustering,” *Scientific Reports*, vol. 14, pp. 1–11, 12 2024. [Online]. Available: <https://doi.org/10.1038/s41598-024-57932-z>
- [13] D. Srinivasan, A. Kiran, S. Parameswari, and J. Vellaichamy, “Energy efficient hierarchical clustering based dynamic data fusion algorithm for wireless sensor networks in smart agriculture,” *Scientific Reports*, vol. 15, pp. 1–24, 12 2025. [Online]. Available: <https://doi.org/10.1038/s41598-024-85076-7>
- [14] Y. Djafari, A. R. Arshi, and H. Rajabi, “Hierarchical clustering approach to movement smoothness and temporal adaptation in rhythmic step aerobics training in middle aged women,” *Scientific Reports*, vol. 15, pp. 1–14, 12 2025. [Online]. Available: <https://doi.org/10.1038/s41598-025-19228-8>
- [15] L. Wang and H. H. Hsu, “Iot technology in maritime logistics management: exploration of data analysis methods,” pp. 1–21, 12 2025. [Online]. Available: <https://doi.org/10.1007/s43926-025-00167-9>

- [16] K. Jung, S. Biswas, and C. Palamidessi, “Mitigating membership inference vulnerability in iterative federated clustering algorithm,” in *ARTMAN 2025 - Proceedings of the Workshop on Recent Advances in Resilient and Trustworthy MACHine learning-driveN systems*. Association for Computing Machinery, Inc, 11 2025, pp. 1–12. [Online]. Available: <https://doi.org/10.1145/3733821.3763022>
- [17] D. Fan, L. Fan, F. Zhao, H. Sun, and X. Min, “An online learner clustering algorithm incorporating autoencoder and canopy-kmeans,” in *Proceedings of 2024 2nd International Conference on Information Education and Artificial Intelligence, ICIEAI 2024*. Association for Computing Machinery, Inc, 5 2025, pp. 627–633. [Online]. Available: <https://doi.org/10.1145/3724504.3724608>
- [18] X. Lian, J. Chen, and C. Duan, “Research on data analysis of vacuum outgassing characteristics of encapsulating materials based on hybrid clustering algorithm.” Association for Computing Machinery (ACM), 11 2025, pp. 180–185. [Online]. Available: <https://doi.org/10.1145/3784013.3784041>
- [19] A. Chowdhury, A. Pal, A. Raut, and M. Kumar, “Kihcdp: An incremental hierarchical clustering approach for iot data using dirichlet process,” *IEEE Access*, vol. 12, pp. 56 019–56 032, 4 2024. [Online]. Available: <https://doi.org/10.1109/ACCESS.2024.3385628>